

Dimensión 1 — Planificación Financiera y Costos del Sistema de IA

Qué es esto: un asistente automático que responde a los clientes por WhatsApp (consultas de venta, posventa y reclamos) usando inteligencia artificial de Google (Gemini). **Autor:** *[Nombre Apellido]*

En una frase: el sistema responde solo la mayoría de las consultas, cuesta centavos por mes en IA y reemplaza muchas horas de atención manual.

Los costos de IA se midieron consultando el consumo real en **Google AI Studio** (el panel de Google donde se ve cuánto se usó). El volumen de consultas y el costo de una hora de trabajo son estimaciones que se pueden ajustar.

1. ¿Cómo sabemos si funciona bien? (KPIs)

Estos son los indicadores que la dirección puede mirar para saber si el sistema rinde:

Indicador	Qué significa	Objetivo
Consultas resueltas solas	% de consultas que la IA responde sin ayuda humana	85 de cada 100
Calidad de las respuestas	Nota promedio de la respuesta (de 1 a 5)	4 o más

Rapidez	Cuánto tarda en responder	Menos de 15 segundos
Horas ahorradas	Tiempo de personas que la IA evita	Cuanto más, mejor
Costo por consulta	Cuánto cuesta cada respuesta	Menos de 1 centavo

Todos estos datos se sacan solos: el sistema los guarda automáticamente en una planilla y en su panel de control. No hay que medir nada a mano.

2. ¿Cuánto "consume" el sistema?

La IA cobra por "tokens" (unidades de texto que lee y escribe). Cada parte del sistema consume una cantidad:

- El **clasificador** (decide si es venta, posventa o reclamo): es la parte que más consume.
- Los **asistentes** que responden a cada tipo de consulta: consumo medio.
- El **revisor de calidad** y el **corrector**: consumo bajo.

Cómo medimos el costo de cada parte por separado: a cada componente (el filtro de seguridad, el clasificador, cada asistente, el revisor y el corrector) le asignamos su **propia llave de acceso** (API key) de Google Gemini. Como Google muestra el consumo por llave, así vemos exactamente cuánto gasta cada parte, en lugar de un número total mezclado. Esto permite saber qué componente conviene optimizar.

Idea clave: la parte que más consume repite siempre el mismo texto. Ese texto se puede "guardar en caché" (memorizar) para no pagarlo cada vez. Es la principal forma de bajar el costo.

3. ¿Cuánto cuesta? (el número importante)

Precio de la IA que usamos: muy bajo (es el modelo más económico de Google). ⚠ Este modelo deja de estar disponible en octubre de 2026; el reemplazo cuesta un poco más, así que lo calculamos con los dos precios.

Costo de cada consulta respondida: menos de 1 centavo de dólar.

Costo por mes según cuántas consultas lleguen:

Consultas por mes	Costo de IA (hoy)	Costo de IA (reemplazo)
2.000	~US\$3	~US\$8
5.000	~US\$8	~US\$21
10.000	~US\$16	~US\$42

Costo total del sistema por mes (sumando la IA + las herramientas donde funciona): **entre US\$30 y US\$90**. La IA en sí es la parte más barata; lo demás son las plataformas de apoyo.

4. ¿Cómo bajamos los costos?

- **Memorizar (caché):** guardar el texto que se repite siempre para no pagarlo en cada consulta.
 - **Enviar solo lo necesario:** darle a la IA únicamente la información que necesita para cada consulta, no todos los manuales completos.
 - **Usar el modelo más barato:** todo el sistema usa la opción más económica de Google, no una más cara de lo necesario.
-

5. Cómo evitamos gastos accidentales

Para que un error de programación no dispare gastos, separamos las "llaves de acceso" a la IA:

Uso	Límite de gasto
Pruebas	tope máximo de US\$5 a US\$10 por mes
Sistema real	aviso cuando llega al 80 % del presupuesto

Así, si algo falla mientras se prueba, el gasto se corta antes de convertirse en un problema.

6. ¿Conviene? (el retorno)

Comparamos hacer el trabajo a mano vs. con el sistema:

	A mano	Con IA
Costo de responder una consulta	~40 centavos	menos de 1 centavo
Ahorro	—	casi 100 %

Con 5.000 consultas por mes: atenderlas con personas costaría unos **US\$2.000**; con la IA cuesta unos **US\$8** de tokens. **Ahorro estimado: alrededor de US\$2.000 por mes.**

Además del ahorro en dinero:

- Atiende las 24 horas, todos los días, sin pagar horas extra.
- Cada respuesta pasa por un control de calidad automático antes de enviarse.
- Queda registro de todo lo que hace, para poder revisarlo después.

Conclusión: el costo de la IA es tan bajo que el sistema conviene prácticamente desde la primera semana. Con lo que se ahorra en una sola hora de trabajo humano, se paga la IA de miles de consultas